

TerraVista — Relatório Técnico

Global Solution 2026.1 (SUB GS) — Graduação ON em Inteligência Artificial · FIAP

Autor: Gabriel Mule — RM 560586

- Repositório: <https://github.com/fiap-ai/2TIAOR-global-solution-sub-2026.1>
 - Aplicação web (Vercel): <https://2-tiaor-global-solution-sub-2026-1.vercel.app>
 - API (Swagger): <https://twotiaor-global-solution-sub-2026-1.onrender.com/docs>
 - APK Android (EAS Build): <https://expo.dev/accounts/gabemule/projects/terravista/builds/3ab21b76-ba40-4a2b-8c3a-02771dd9fff0>
 - Vídeo demonstrativo (YouTube não listado): https://youtu.be/sy-_nimLjFo
 - Simulação IoT ao vivo: <https://wokwi.com/projects/466934430632875009>
-

1. Introdução

A economia espacial deixou de ser puramente científica: satélites hoje monitoram o clima, apoiam segurança, viabilizam rastreamento global, auxiliam na prevenção de desastres e produzem grandes volumes de dados usados por governos, empresas e centros de pesquisa. O desafio da SUB GS 2026.1 pergunta:

Como tecnologias avançadas de Inteligência Artificial e computação podem impulsionar a nova economia espacial e gerar impacto positivo na Terra?

A TerraVista responde com uma plataforma de Observação da Terra (Earth Observation, EO) que funde dados orbitais (índices de vegetação / NDVI) com estações de campo IoT (ESP32), processados por IA, para entregar dois resultados de igual peso:

- Prevenção de desastres — detecção de risco de incêndio, seca e estresse hídrico sobre um território a partir de telemetria e imagens.
- Proteção agrícola — monitoramento do vigor da lavoura e emissão de alertas de manejo para produtores.

A economia espacial é o vetor de dados: o sensoriamento remoto orbital é a fonte primária que, combinada com sensores de borda e modelos de IA, vira inteligência acionável em terra.


1.1 Objetivos

- Entregar um MVP funcional cobrindo os requisitos mínimos da GS: IA generativa, visão computacional, machine learning, análise de dados, APIs, dashboards e sensores/ESP32/Edge.
 - Construí-lo full-stack: backend (FastAPI), ML (RandomForest), visão (ExG + YOLO), web (React), mobile (Expo), IoT (MicroPython/Wokwi).
 - Documentar tudo: READMEs, diagrama de arquitetura, este relatório e um roteiro de vídeo.
-

2. Desenvolvimento

2.1 Visão geral da arquitetura

A TerraVista é organizada como módulos independentes integrados por um backend FastAPI. O backend reutiliza exatamente os artefatos treinados dos módulos de ML e visão (importados por caminho), de modo que o pipeline servido nunca diverge do que foi treinado e testado.



Diagramas completos (visão de sistema + sequências de requisição) estão em `architecture.md`.

2.2 Taxonomia de risco compartilhada

Toda capacidade — ML tabular, visão computacional e a borda IoT — fala a mesma linguagem de 3 classes:

Classe	Rótulo	Significado
0	HEALTHY	parcela bem irrigada, vegetação vigorosa, baixo risco de fogo
1	ATTENTION	sinais iniciais de estresse, recomenda-se monitorar/irrigar
2	CRITICAL	estresse hídrico severo / alto risco de fogo / perda de safra

2.3 Machine Learning (mL/)

Uma estratégia híbrida de dados mantém o MVP totalmente reproduzível ao mesmo tempo em que o ancora na realidade: o modelo treina sobre um dataset sintético com semente fixa cujos coeficientes são validados contra datasets reais (checagem direcional de correlação).

- Núcleo sintético: `generator.py` (seed 42) — coeficientes física e agronomicamente plausíveis; fonte única de verdade para features e classes.
- Camada de dados reais (validada): UCI Forest Fires (517 linhas), Kaggle Crop Recommendation (2200), NASA FIRMS focos ao vivo (787) — usados para EDA e calibração, não como rótulos de treino.

Features → alvo:

Feature	Unidade	Domínio de origem
air_temperature	°C	estação de campo IoT
air_humidity	%	estação de campo IoT
soil_moisture	%	estação de campo IoT
solar_radiation	W/m²	estação de campo IoT
ndvi	0–1	Observação da Terra (satélite)
days_since_rain	dias	EO / meteorologia
wind_speed	km/h	estação de campo IoT
risk_class	0/1/2	risco combinado desastre + agro (alvo)

Modelo e avaliação: `RandomForestClassifier(n_estimators=300, max_depth=12, min_samples_leaf=5, class_weight="balanced", random_state=42)`, split estratificado 80/20. A avaliação foca no recall da classe CRITICAL — o erro mais caro é deixar passar uma parcela crítica (fogo/seca/perda não detectados). Métricas de referência (seed 42): `recall(CRITICAL) ≈ 0,80`, `F1 macro ≈ 0,69`, com `soil_moisture` e `ndvi` como principais fatores — coerente com o desenho físico do gerador.

O modelo é serializado como um bundle para que o backend faça inferência sem re-derivar metadados:

```
{
  "model": RandomForestClassifier, # estimador treinado
  "feature_columns": [...],       # ordenação exata das entradas
  "class_names": {0: "HEALTHY", 1: "ATTENTION", 2: "CRITICAL"},
  "version": "1.0.0",
}
```

2.4 Visão Computacional (**vision/**)

Duas camadas complementares, ambas consumidas por `/api/vision/analyze`:

1. Análise de cena por índice de vegetação (`detector.py`, autoral e offline). Calcula o Excess Green Index $ExG = 2g - r - b$ a partir das coordenadas cromáticas por pixel — um proxy RGB de NDVI quando não há banda do infravermelho próximo — e deriva três frações interpretáveis:
 - `vegetation_fraction` (dossel vigoroso, $ExG > 0,06$)
 - `dryness_fraction` (solo nu/queimado avermelhado-amarronzado)
 - `smoke_fraction` (pixels cinza brilhantes e de baixa saturação)

Um conjunto de regras monotônico e auditável mapeia essas frações para uma classe de risco.

2. Detecção de objetos (opcional, Ultralytics YOLO `yolo8n`) — sinaliza veículos, pessoas, barcos e aeronaves em imagens reais, e degrada com elegância para uma lista `detections` vazia se os pesos não estiverem disponíveis.

Validação nas cenas sintéticas seed-42 — as três classes corretas:

Cena	Risco	Vegetação	Seca	Fumaça
healthy	HEALTHY	0,956	0,021	0,000
attention	ATTENTION	0,515	0,241	0,000
critical	CRITICAL	0,267	0,381	0,066

O ExG é um índice consolidado (Woebbecke et al., 1995); usá-lo como proxy de NDVI apenas com RGB é uma simplificação honesta e documentada para o MVP. A evolução para NDVI real (bandas NIR) está descrita em `professionalization.md`.

2.5 API Backend (**backend/**)

Serviço FastAPI expondo 9 endpoints sob `/api/`:

Método	Rota	Finalidade
GET	<code>/api/health</code>	Liveness + disponibilidade do modelo
POST	<code>/api/auth/login</code>	Login mock → bearer token
POST	<code>/api/predict</code>	Classifica uma parcela a partir de 7 features
POST	<code>/api/vision/analyze</code>	Classifica uma cena RGB enviada
POST	<code>/api/chat</code>	Assistente de IA (OpenRouter, fallback mock)
POST	<code>/api/sensors/readings</code>	Armazena uma leitura ESP32 (auto-classificada)
GET	<code>/api/sensors/readings</code>	Lista leituras recentes
GET	<code>/api/sensors/latest</code>	Última leitura + veredito
GET	<code>/api/knowledge</code>	Ações de mitigação (opcional <code>?risk_label=</code>)

O assistente de chat degrada com elegância através de uma cadeia de fallback de 3 níveis para que a demo nunca quebre: (1) modelo primário gratuito, (2) fallback pago barato caso o gratuito esteja com rate-limit/erro, (3) mock offline determinístico ancorado na base de conhecimento. O campo `source` da resposta informa qual nível respondeu.


A persistência de sensores usa por padrão uma deque em memória e migra de forma transparente para o Supabase quando as variáveis de ambiente estão presentes — a demo é autossuficiente nos dois casos.

2.6 Estação de Campo IoT (**iot/**)


ESP32 simulado (MicroPython, Wokwi — sem hardware físico) que lê sensores, calcula uma dica de risco na borda (feedback por LED) e faz POST de cada leitura para `/api/sensors/readings`, que a reclassifica com o modelo de ML treinado.

Feature do modelo	Origem na simulação	Origem no mundo real
<code>air_temperature / air_humidity</code>	DHT22	DHT22 / SHT31
<code>soil_moisture</code>	potenciômetro (proxy)	sonda capacitiva de solo
<code>solar_radiation</code>	LDR	piranômetro
<code>ndvi / days_since_rain / wind_speed</code>	proxies derivados	satélite / meteorologia / anemômetro

Simulação ao vivo: <https://wokwi.com/projects/466934430632875009>. Um LCD 16×2 mostra o risco atual e as leituras principais; três LEDs (verde/amarelo/vermelho) espelham o veredito HEALTHY/ATTENTION/CRITICAL.



Estação ESP32 na Wokwi — leituras de seca acionam o veredito CRITICAL na borda (LED vermelho aceso) antes do POST para o backend.




A mesma estação com parcela bem irrigada — veredito HEALTHY na borda (LED verde aceso).


2.7 Clientes Web e Mobile

- Web (web/) — React + Vite + TypeScript + shadcn/ui, tema escuro. Páginas: Login, Dashboard (timeline Recharts + KPIs), Predict, Vision, Chat, Knowledge. Deploy via vercel.json.
- Mobile (mobile/) — React Native + Expo + React Native Paper, navegação em drawer, as mesmas seis telas. O Dashboard usa react-native-chart-kit; a Vision usa expo-image-picker; o Chat renderiza markdown com uma lista que se fixa ao final. APK via EAS (eas.json).


Ambos os clientes compartilham uma camada de API tipada e enxuta e a mesma linguagem de cores de risco. As capturas abaixo são do app mobile rodando contra o mesmo backend.



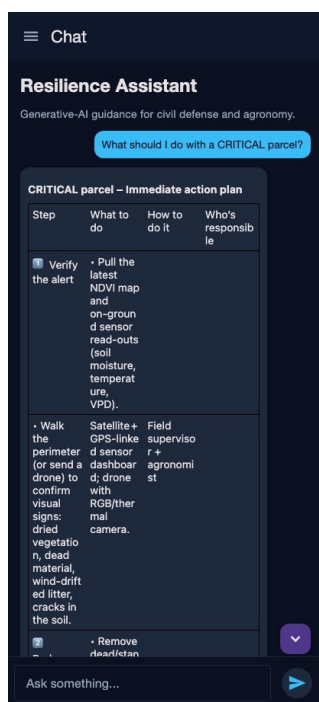
Mobile — Dashboard com KPIs (34,9 °C / 14% / NDVI 0,27) e timeline de telemetria (*react-native-chart-kit*).



Mobile — Predict com veredito CRITICAL (94,9%) a partir das 7 features da parcela.




Mobile — Vision classificando uma cena enviada como ATTENTION (62%) via índice ExG.



Mobile — Assistente de Resiliência entregando um plano de ação para uma parcela CRITICAL.

2.8 Passo a passo da interface web

As capturas abaixo foram obtidas ao vivo do cliente web rodando contra o backend, ilustrando cada capacidade de ponta a ponta.



Login — autenticação mock por bearer token protegendo o console do operador.



Dashboard — KPIs e uma timeline de telemetria (Recharts) derivando de HEALTHY → CRITICAL, alimentada pelo armazenamento de sensores.

 TerraVista
Earth Observation

Dashboard

Predict

Vision

Assistant

Knowledge

Territorial Risk Prediction

Score a land parcel from its environmental features using the trained model.

Parcel features

Adjust the 7 inputs and run the model.

Quick presets (fills the form and scores it):

HEALTHY ATTENTION CRITICAL

Air temperature (°C)

39

Air humidity (%)

18

Soil moisture (%)

8

Solar radiation (W/m²)

950

NDVI

0,18

Days since rain (days)

30

Wind speed (km/h)

35

Run prediction

Feature reference — typical range per risk class:

Feature	Healthy	Attention	Critical
Air temperature (°C)	18–28	28–35	> 35
Air humidity (%)	> 55	30–55	< 30
Soil moisture (%)	> 45	20–45	< 20
Solar radiation (W/m²)	< 550	550–800	> 800

Verdict

Model output and class probabilities.

Reading the verdict

The bars are the model's confidence in each class; the highest one is the predicted risk.

[Learn more](#)

Risk class

CRITICAL

HEALTHY

0.2%

ATTENTION

4.8%

CRITICAL

94.9%

Predict — uma parcela classificada como CRITICAL (≈94,9%) a partir das suas 7 features.

TerraVista
Earth Observation

Dashboard

Predict

Vision

Assistant

Knowledge

admin

Sign out

Computer Vision

Analyze an aerial/satellite image: vegetation, dryness and smoke fractions.

How the scene analysis works

An authorial remote-sensing heuristic estimates territorial risk from an ordinary RGB image — no near-infrared band required.

Learn more

Upload image

PNG, JPEG or WEBP.

Choose another image

Or try a real sample (one click):

HEALTHY

ATTENTION

CRITICAL

Result

Scene classification and indices.

CRITICAL

confidence 69%

0 detection(s)

Vegetation

4.8%

Dryness

19.1%

Smoke

8.6%

Vision — uma cena de incêndio enviada e classificada como CRITICAL via índice ExG.

TerraVista
Earth Observation

Dashboard

Predict

Vision

Assistant

Knowledge

admin

Sign out

Knowledge Base

Recommended mitigation and management actions per risk level.

How risk levels map to action

Each card maps a risk level to the field actions that mitigate it.

Learn more

HEALTHY

Healthy parcel — maintain and monitor

Keep the routine satellite/NDVI monitoring cadence (weekly).

Maintain current irrigation schedule; avoid over-watering.

Log baseline soil moisture and NDVI for trend comparison.

No civil-defense action required.

ATTENTION

Attention — early stress, act preventively

Increase monitoring frequency (every 2-3 days).

Inspect irrigation lines; consider a supplemental watering cycle.

Check for early pest/disease signs in the stressed sub-areas.

Prepare firebreaks if dryness and wind are rising.

Notify the field agronomist for a ground check.

CRITICAL

Critical — high fire/drought/yield-loss risk

Trigger civil-defense alert for the affected area.

Activate emergency irrigation where feasible; prioritize hotspots.

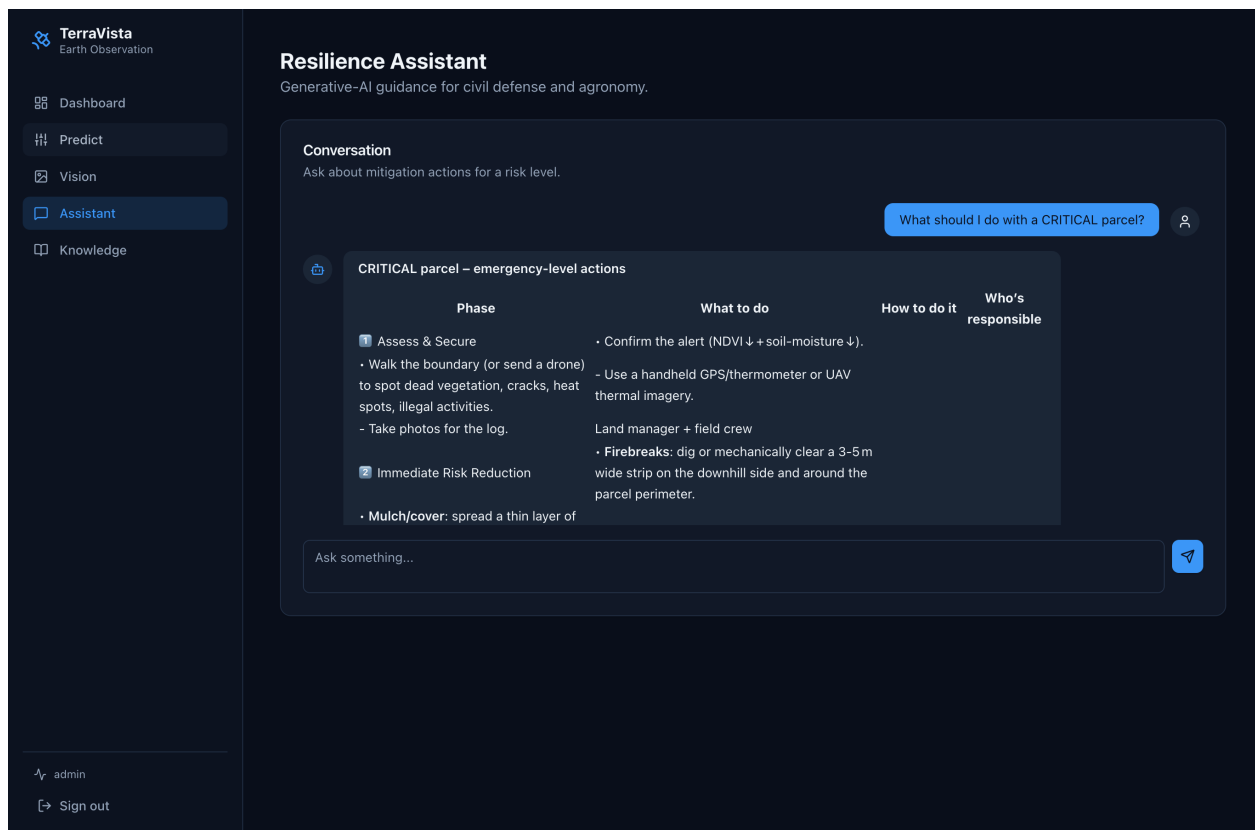
Clear/expand firebreaks and stage firefighting resources.

Restrict access and machinery that can ignite dry vegetation.

Cross-check with NASA FIRMS active-fire detections in the region.

Plan crop-loss mitigation and insurance documentation.

Base de conhecimento — ações de mitigação/manejo por nível de risco.



Assistente de Resiliência — uma resposta ao vivo do OpenRouter com um plano de ação para uma parcela CRITICAL.

2.9 Principais decisões de projeto (ADRs)

- Sem lógica duplicada: o backend importa os artefatos de ML/visão por caminho.
- ML com recall em primeiro lugar: uma parcela CRITICAL não detectada é o erro mais caro.
- Chat capaz de operar offline: fallback de 3 níveis (gratuito → pago → mock).
- Reprodutibilidade: semente fixa 42 → dataset e modelo idênticos a cada execução.
- Simplificações honestas: ExG como proxy RGB de NDVI; armazenamento em memória; autenticação mock — todas documentadas com um caminho de evolução para produção.

3. Resultados Esperados

- Prevenção de desastres: identificação precoce de parcelas de alto risco (fogo / seca) a partir da fusão de telemetria + imagens, exibida em um dashboard ao vivo com vereditos por cor e orientações de mitigação geradas por IA.
- Proteção agrícola: monitoramento contínuo do vigor da lavoura e alertas de manejo, ajudando a reduzir a perda de safra.
- MVP demonstrável: todos os requisitos mínimos da GS são exercitados de ponta a ponta — IA generativa (chat), visão computacional (análise de cena), ML (classificador de risco), dados/APIs/dashboards (FastAPI + web/mobile) e sensores/ESP32/Edge (estação Wokwi). Métricas de referência: recall(CRITICAL) $\approx 0,80$; visão 3/3 cenas corretas.

4. Conclusões

A TerraVista mostra como dados da economia espacial — Observação da Terra orbital — combinados com IoT de borda e IA acessível podem produzir impacto terrestre tangível tanto em prevenção de desastres quanto em agricultura, usando um MVP reproduzível e totalmente testável. A arquitetura é deliberadamente modular e honesta quanto às suas simplificações, cada uma acompanhada de um caminho documentado rumo a hardware profissional e dados de satélite reais (ver [professionalization.md](#)). O resultado é uma prova de conceito coerente e de ponta a ponta, que mapeia diretamente os critérios de avaliação da GS ao mesmo tempo em que se mantém como uma base crível para um sistema de produção.

5. Referências e Links

- Repositório: <https://github.com/fiap-ai/2TIAOR-global-solution-sub-2026.1>
- Aplicação web (Vercel): <https://2-tiaor-global-solution-sub-2026-1.vercel.app>
- API (Swagger): <https://twotiaor-global-solution-sub-2026-1.onrender.com/docs>
- APK Android (EAS Build): <https://expo.dev/accounts/gabemule/projects/terravista/builds/3ab21b76-ba40-4a2b-8c3a-02771dd9fff0>
- Vídeo demonstrativo (YouTube não listado): https://youtu.be/sy-_nimLjFo
- Simulação IoT ao vivo: <https://wokwi.com/projects/466934430632875009>
- Woebbecke, D. M. et al. (1995). Color indices for weed identification. — base para o Excess Green Index (ExG).
- Fontes de dados: UCI Forest Fires, Kaggle Crop Recommendation, NASA FIRMS.